

2020-2025 中英文经济学顶刊文献 热词挖掘与研究领域分析

倪嘉越

2026 年 8 月 4 日

目录

1 数据获取	2
1.1 英文 Top 5 期刊	2
1.2 中文期刊	2
2 数据清洗和处理	3
2.1 英文 Top 5 数据处理	3
2.2 中文数据过滤	3
3 领域热词云图与特征挖掘	4
3.1 短语挖掘方法	4
3.2 停用词过滤与统计机制	4
3.3 热词挖掘结果	4
3.3.1 英文 Top 5 热词结果	4
3.3.2 中文期刊热词结果	4
4 研究领域趋势变化结果	7
4.1 方法一：TF-IDF 与向量空间模型（VSM）	7
4.2 英文 Top 5 结果与分析	7
4.3 中文期刊结果与分析	8
4.4 方法二：基于深度语义嵌入与决策机制的改进方法	9
4.4.1 与方法一（传统 TF-IDF 与 VSM）的核心差异	9
4.4.2 分类结果与方法对比	9

做的改变：

1. 由于热门领域本身发表的文章就多，且出于中英文操作方式统一的考虑，去掉引用量加权相关操作。 2. 优化了数据清洗和处理结果，确保中英文文章都是经济学相关的、2020-2025 的文章。 3. 加入短语挖掘部分（利用 LLR），诸如 field experiment, moral hazard, 一带一路，数字经济等短语可以更好地体现热门领域和热门话题趋势。 4. 为避免热词中大量存在无意义的副词、动词或经济学泛词，加入停用词表，过滤这些词汇。 5. 为证明 TF-IDF 的方法比黑箱模型有优势，以英文 top5 的分类为例引入方法二进行对比。

1 数据获取

1.1 英文 Top 5 期刊

【搜索范围】通过上海交通大学图书馆检索入口，采集 Web of Science (WoS) 数据库中经济学 Top 5 顶级期刊（包括 *American Economic Review*, *Journal of Political Economy*, *Quarterly Journal of Economics*, *Econometrica*, *Review of Economic Studies*）在 2020–2025 年间发表的全部文章。检索字段涵盖：题名 (Title)、作者 (Author)、摘要 (Abstract)、关键词 (Keywords)、JEL 领域分类（几乎都是 Economics; Business & Economics）及引用量。




图 1: 英文 Top 5 搜索范围

【搜索得到】初始检索共获取 Article 类型文献 2,658 篇。在初步筛查中发现部分“不含摘要的评论、书评及勘误类文章”和“年份等数据不符要求的文章”，经数据过滤与清洗后，剩余符合要求文献 2499 篇，数据统一存储于 `Cleaned_Top5_Journals_Dataset.csv` 中。




图 2: 英文 Top 5 检索结果

1.2 中文期刊

【搜索范围】从中国知网 (CNKI) 获取《经济研究》、《管理世界》以及《中国社会科学》（仅筛选经济学相关文章）期刊，系统采集 2020 年至 2025 年的学术文献。

【搜索得到】 初始共获取相关文献 2,126 篇。剔除建院周年公告、征稿启事及非学术文件、年份不符合 2020-2025 的文献以及《中国社会科学》中和经济学关联不大的文献（主要为政治军事相关），共计保留有效文献 1805 篇，存储于 Cleaned_Custom_Dataset.csv 中。



图 3：中文期刊搜索范围与结果

2 数据清洗和处理

2.1 英文 Top 5 数据处理

1. **自动合并与格式校验**：编写 Python 脚本通过 glob 模块自动扫描并兼容读取多份 Web of Science (WoS) 导出的制表符分隔文本 (TSV/TXT)。
2. **布尔掩码清洗**：
 - **分流一**：针对缺失摘要 (Abstract) 的记录执行硬隔离导出 (存放在 Missing_Abstracts_Records.csv 不参与后续计算)。
 - **分流二**：检查核心元数据 (Title, Year, Author) 的完整性，确保无字段缺失。
 - **分流三**：留存无缺损的有效文献进入特征工程。
3. **文本构建与结构加权**：为强化核心字段对领域归属的决定作用，对文本进行结构加权：

$$\text{Full_Text} = (\text{Title} \times 2) + (\text{Keywords} \times 2) + \text{Abstract}$$

2.2 中文数据过滤

去除《中国社会科学》中非经济类文章方式如下：（通过标题、关键词和摘要判断）

若文本中含有非经济学标记（如“马克思主义”、“哲学”、“地缘政治”等），则检查是否包含强经济学关键词（如“金融”、“GDP”、“面板”等），若不含则判定为非经济学文章，直接剔除。

若无非经济学标记，则统计强经济学关键词命中数（ ≥ 1 则保留）和弱经济学关键词（如“经济”、“市场”、“企业”等）命中数（ ≥ 3 则保留）。满足任一条件即视为经济学文章。

后进行人工核验，发现上述清洗效果已经很好，仅少数分类错误。**【其余处理与英文类似】**

3 领域热词云图与特征挖掘

通过对综合文本的挖掘与统计，提取出高频热门词汇与复合短语，可以直观反映出近几年经济学研究的聚焦点。

3.1 短语挖掘方法

基于对数似然比 (LLR) 模型从全部文本中自动提取 2-gram 与 3-gram 候选短语。英文文本处理直接依托 NLTK 库的统计共现分析，中文则通过自编类似逻辑实现。LLR 计算公式为：

$$LLR = 2 \left(k \ln \left(\frac{k}{E} \right) + (N - k) \ln \left(\frac{N - k}{N - E} \right) \right) \quad (1)$$

其中 k 为实际共现频次， N 为总词数，期望共现频次 $E = \frac{n_1 \cdot n_2}{N}$ 。可筛选出统计意义上高度显著的专业短语。因为 LLR (在大样本下) 渐进服从自由度为 1 的卡方分布 (χ^2)，如数字经济 (LLR=1838.94, freq=394) 这样的词汇就可以认定为专业词汇。

3.2 停用词过滤与统计机制

构建了覆盖虚词、通用动词、学术套话及经济学泛用词汇的多维停用词表 (STOP)。在分词与统计阶段执行严格清洗 (单词短语分开统计)：

- **单字/核心词独立统计**：对原始文本直接分词、词形还原与停用词过滤，计算单字词频。
- **复合短语独立统计**：先进行短语挖掘，将挖掘出的高质量短语替换为下划线形式 (如 *labor_market*)，独立提取并计算其结构加权频次。

3.3 热词挖掘结果

3.3.1 英文 Top 5 热词结果

【现象】从图 4 的统计结果来看，英文 Top 5 领域特定短语 (Key Phrases) 与 Top 10 领域特定单词 (Single Words) 呈现出一定特征：英文 Top 5 领域短语依次为 *field experiment* (155)、*adverse selection* (153)、*moral hazard* (140)、*labor supply* (106) 和 *job search* (106)；Top 10 单词频次均超过 700，其中 *equilibrium* (1375) 与 *risk* (1187) 断层领先，其后为 *income*、*tax*、*wage*、*labor*、*demand*、*welfare*、*productivity* 和 *competition*。直观云图见图5。

【分析】*field experiment* 体现当前实证方法的流行；*adverse selection* 和 *moral hazard* 反映了英文期刊中微观经济学的热度；*labor supply* 和 *job search* 则对应劳动经济学。单词层面，*equilibrium* 的词频最高，说明均衡分析是经济学建模的基础，而 *risk*、*demand*、*competition* 等词的高频覆盖了不确定性、市场结构和资源配置等各种各样的议题。

3.3.2 中文期刊热词结果

【现象】图6可见 Top 5 短语分别为一带一路 (114)、数字经济 (98)、全要素生产率 (70)、高质量发展 (67) 和新质生产力 (51)；Top 10 核心单字/单词则以中国 (1155) 和企业 (1136) 居首，其余包括市场、政府、风险、信息、改革、技术、产业和社会。云图见图7。

【分析】复合短语和我国政策关联度大一些。而高频词汇中中国与企业的断层领先以及政府、市场的并重，体现了中文经济学文献和国家战略、产业组织等高度关联的特征。

Top 5 Domain-Specific Key Phrases		
#1	field experiment	155
#2	adverse selection	153
#3	moral hazard	140
#4	labor supply	106
#5	job search	106
Top 10 Domain-Specific Single Words		
#1	equilibrium	1375
#2	risk	1187
#3	income	1069
#4	tax	868
#5	wage	837
#6	labor	818
#7	demand	816
#8	welfare	793
#9	productivity	786
#10	competition	734

图 4: 英文 Top 5 - 热词统计结果



图 5: 英文 Top 5 领域热词云图

Top 5 领域复合短语		
#1	一带 一路	114
#2	数字 经济	98
#3	全要素 生产率	70
#4	高质量 发展	67
#5	新质 生产力	51
Top 10 领域核心单字/单词		
#1	中国	1155
#2	企业	1136
#3	市场	559
#4	政府	392
#5	风险	338
#6	信息	327
#7	改革	327
#8	技术	325
#9	产业	298
#10	社会	297

图 6: 中文期刊 - 热词统计结果



图 7: 中文期刊领域热词云图

4 研究领域趋势变化结果

4.1 方法一：TF-IDF 与向量空间模型 (VSM)

采用标准的零样本特征空间匹配框架：

1. TF-IDF 权重计算：

词频 (TF)

$$\text{TF}_{t,d} = \frac{f_{t,d}}{\sum_{t' \in d} f_{t',d}} \quad (2)$$

逆文档频率 (IDF)

$$\text{IDF}_t = \log \left(\frac{N}{1 + |\{d \in D : t \in d\}|} \right) \quad (3)$$

最终权重

$$\text{TF-IDF}_{t,d} = \text{TF}_{t,d} \times \text{IDF}_t \quad (4)$$

2. 向量空间模型 (VSM)：将待分类文献向量与各大经典经济学领域的关键词向量统一映射至高维稀疏特征空间。(关键词见文末附录)

3. 余弦相似度判定：

$$\text{Similarity}(\vec{d}, \vec{c}_j) = \cos(\theta) = \frac{\vec{d} \cdot \vec{c}_j}{\|\vec{d}\| \|\vec{c}_j\|} \quad (5)$$

4.2 英文 Top 5 结果与分析

Predicted_Field	
Microeconomics	374
Labor Economics	328
Development Economics	305
Miscellaneous & Methods	296
Public Finance	288
Macroeconomics	264
Finance	219
Industrial Organization	195
International Economics	135
Economic History	95

图 8：2020-2025 Top 5 期刊论文领域分类划定结果

结论：Top-5 Economics Journals 的研究主题具有较强稳定性。微观经济学依旧是 Top-5 期刊最核心的基础研究方向；发展经济学有一定波动，可能和 2024 年有一些后疫情时代发展的研究发表导致短期有所上涨有关；劳动经济学重要性逐渐提升；其余门类均保持稳定。




图 9: 2020-2025 Top 5 期刊论文领域分类变化趋势

4.3 中文期刊结果与分析

Predicted_Field	
产业组织	381
金融学	283
发展经济学	240
经济史	202
劳动经济学	175
宏观经济学	161
公共财政	126
国际经济学	118
方法与杂项	66
微观经济学	53

图 10: 2020-2025 中文期刊论文领域分类划定结果

结论：中文顶刊的研究主题整体保持稳定。产业组织和金融学占据最高比例；其中，产业组织在2023 年达到发表高峰，可能和疫情时代企业面临生存压力较大、企业市场进出和数字化转型等成为热点有关；劳动经济学占比整体呈缓慢上升趋势。其余领域保持相对稳定。




图 11: 2020-2025 中文期刊领域分类变化趋势

4.4 方法二：基于深度语义嵌入与决策机制的改进方法

4.4.1 与方法一（传统 TF-IDF 与 VSM）的核心差异

(Galofré-Vilà, 2026) 文章中自始至终应该都用的是基于“TF-IDF + 余弦相似度”的方法，区别在于领域描述的输入形式不同（该论文中方法二用的是简洁的 key word list，也就是本文的方法一，基于高维稀疏的词频矩阵（TF-IDF）和向量空间模型（VSM），主要匹配字面词共现）。很容易有以下疑惑：该方法无法很好地捕捉深层上下文和同义词变体，是否效果不如深度学习模型？以下以英文 top5 期刊分类为例做了一个黑箱模型的尝试：

1. 模型架构：Sentence-BERT (all-MiniLM-L6-v2) 稠密语义空间

- 这是一个基于 Transformer 的轻量级语义模型，由微软开源的 MiniLM 变体经微调而来。模型体积小、速度快，但应该足以完成分类任务。
- 与方法一仅依赖词频不同，该模型将任意长度的文本直接转换为 384 维的稠密向量，理论上可以捕捉句子或段落级别的深层语义（领域定义仍用原词表）。

2. 长文本处理策略：自适应分块与最大池化 (Max-Pooling)

- 由于模型有输入限制，传统方法一般是对超长文本直接进行硬截断，但容易丢失信息。
- 本方法实现了一个专门的 `encode_adaptive_texts` 函数：当文本长度在模型固定限制内时直接编码；若文本超长，则将其按 Token 切分成多个块 (chunk) 分别编码成向量，最后对所有块向量按维度取最大值 (Max-Pooling) 并重新归一化。这最大程度地保留了长文本中各个片段最显著的语义特征。

3. **决策机制：**本方法设定了严格的阈值 (`similarity_threshold = 0.35`)：若最高相似度（相似度计算仍是领域词表向量和文章向量做 $\cos$ 运算） ≥ 0.35 ，则归入对应的具体领域；若最高相似度 < 0.35 ，说明模型对归属区间不确定，则强制将其归入“Miscellaneous & Methods”（杂项与方法）。

4.4.2 分类结果与方法对比

引入该机制后，分类结果如下图13所示。在和方法一分类结果图12对比中可以发现，方法二虽然也体现了微观和劳动的主导地位，但有大量其他文献被归入“杂项与方法类”。

Predicted_Field	
Microeconomics	374
Labor Economics	328
Development Economics	305
Miscellaneous & Methods	296
Public Finance	288
Macroeconomics	264
Finance	219
Industrial Organization	195
International Economics	135
Economic History	95

图 12: 方法一分类结果

Predicted_Field	
Miscellaneous & Methods	1261
Microeconomics	388
Labor Economics	215
Macroeconomics	213
Industrial Organization	158
Public Finance	100
Finance	57
International Economics	50
Economic History	30
Development Economics	27

图 13: 方法二分类结果

Sentence-BERT 方法效果不理想的原因主要有两点。一是模型在训练时学习的是完整句子或段落之间的语义相关性，而预训练语料并非以经济学学术文本为主，因此在处理本任务中的学科关键词和论文摘要时，其语义表征往往因缺乏领域针对性而出现信息稀释。二是理论上该方法中领域定义最好应采用一段“可以囊括该领域常见写作逻辑和使用方法”的段落。但一个领域难以用一段有限的文字完整概括其研究方法和分析逻辑，且当采用“一段话”作为领域模板时，其信息密度和代表性远低于关键词列表，无法有效覆盖领域边界。所以经过尝试，哪怕换成用一段话来表述一个领域，效果也差不多。综合以上导致分类结果弱于传统 TF-IDF 方法。另有一个很直接的想法，如果上述方法中的阈值调低一些，是否杂项数量不会这么多？首先调低会造成一定错判风险，其次经过实操、哪怕调低到 0.2 效果也很一般（指杂项数量依然很大）。

除此之外，值得说明的是：黑箱方法中占据优势的近义词理解等在处理学术文本中用处并不大。因为学术用词高度集中（从热词云图就可以发现这一点），每个领域都有自己的专有名词。在此情况下，使用 TF-IDF 会更合理一些。

附录：TF-IDF 中领域特定关键词设定（中英文）

领域	中文关键词	英文关键词
发展经济学 (Development Economics)	贫困、援助、农业、健康、教育、卫生、农村、基础设施、随机实验、田野调查、发展、增长、结构转型、低收入	rct aid poverty agriculture health education sanitation infrastructure rural development structural transformation household welfare field experiment low-income
经济史 (Economic History)	历史、数据、长期、制度、人口、工业、革命、殖民、路径依赖、十九世纪、量化、变迁	cliometrics historical data archival census nineteenth century institutional change demographic transition industrial revolution slavery colonialism path dependence persistence
金融学 (Finance)	资产定价、投资组合、股票、债券、流动性、风险、波动、股息、期权、公司金融、债务、对冲、系统性风险	asset pricing capm portfolio stock bond liquidity risk volatility dividend option corporate debt hedge fund systemic risk
产业组织 (Industrial Organization)	市场结构、反垄断、竞争、进入、垄断、价格、合谋、寡头、生产率、加价、规模经济、网络效应、平台	antitrust market concentration hhi entry barriers monopoly collusion oligopoly vertical restraints productivity markup economies scale network effects platform
国际经济学 (International Economics)	贸易、关税、汇率、跨国投资、价值链、引力模型、区域协定、经常账户、国际收支、全球化、跨国公司	gravity tariffs exchange rate pass-through multinational fdi global value chains current account balance payments wto regional trade agreements
劳动经济学 (Labor Economics)	工资、就业、劳动力、收入不平等、教育回报、人力资本、移民、培训、劳动供给、劳动需求、性别差距	wage employment elasticity worker reallocation schooling returns training internal migration immigration earnings inequality household microdata labor supply demand minimum wage gender gap
宏观经济学 (Macroeconomics)	货币、通胀、财政、经济周期、利率、产出、央行、消费、投资、债务、总需求、政策规则	dsge monetary policy taylor rule inflation expectations fiscal multiplier public debt sustainability consumption smoothing business cycle co-movement aggregate fluctuations
微观经济学 (Microeconomics)	效用、博弈论、均衡、拍卖、机制设计、契约、逆向选择、道德风险、信号、外部性、公共品、福利	utility maximization general equilibrium game theory nash mechanism design auctions adverse selection moral hazard contract signaling perfect competition
公共财政 (Public Finance)	税收、财政支出、补贴、福利、外部性、转移支付、再分配、社保、公共品、最优税收、超额负担	income tax corporate vat social insurance unemployment disability public goods pigouvian externalities transfer payments redistributive welfare state optimal taxation deadweight loss
方法与杂项 (Miscellaneous& Methods)	估计、识别、工具变量、面板数据、双重差分、断点回归、固定效应、广义矩估计、贝叶斯、因果推断、计量	instrumental variables 2sls difference-in-differences regression discontinuity panel data fixed effects random effects gmm asymptotic bayesian causal identification applied econometrics

注：本表为文本挖掘中划分子领域所设定的词典。其中微观侧重于微观理论，宏观侧重于理论和政策研究；其余七项根据具体应用领域区分；“方法与杂项”收集了方法类论文和难以分入其他九项的综合文章。